

Spor Salonu Üyelerinin Egzersiz Analizi: Makine Öğrenmesi Sınıflandırıcıları ile Deneyim Seviyesi Tahmini

Elif Beyza Turan – 221104093

Mehmet Fatih Akay – 231101026

Onur Erçen – 2311010351

Bilgisayar Mühendisliği Bölümü

TOBB Ekonomi ve Teknoloji Üniversitesi, Ankara, Türkiye

ÖZET

Bu çalışma, spor salonu üyelerine ait egzersiz verileri kullanılarak makine öğrenmesi sınıflandırma yöntemlerinin performans analizini sunmaktadır. Çalışma başlangıçta bireylerin tercih ettiği egzersiz türünün (*Workout Type*: Cardio, HIIT, Strength, Yoga) tahmin edilmesini amaçlamış; ancak keşifsel veri analizi (EDA) aşamasında gerçekleştirilen tek yönlü ANOVA testleri, mevcut sayısal özelliklerin hiçbirinin egzersiz türleri arasında istatistiksel olarak anlamlı fark göstermediğini ortaya koymuştur (tüm p-değerleri > 0.05). Bu durum, sınıflandırma modellerinin doğruluklarının rastgele tahmin seviyesine yakın kalmasıyla doğrulanmıştır.

Bu negatif bulgu doğrultusunda çalışma, *Experience Level* (Başlangıç, Orta, İleri) tahminine yönlendirilmiştir. Kaggle kaynaklı, 973 spor salonu üyesine ait 15 orijinal özellik içeren veri seti üzerinde Decision Tree, Random Forest ve RBF çekirdekli Support Vector Machine (SVM) modelleri karşılaştırılmıştır. Ayrıca egzersiz fizyolojisi bilgisine dayalı 7 yeni özellik türetilmiştir. Deneyel sonuçlar, Decision Tree modelinin %90.75 test doğruluğu ile en iyi performansı gösterdiğini; Random Forest'in %92.00 ve SVM'in %86.64 doğruluk elde ettiğini göstermektedir. Özellik önemi analizleri, antrenman süresi ve antrenman sıklığının deneyim seviyesini belirlemede en kritik faktörler olduğunu ortaya koymuştur.

Anahtar Kelimeler— makine öğrenmesi, sınıflandırma, karar ağacı, rastgele orman, SVM, fitness analitiği, deneyim seviyesi tahmini, ANOVA

I. GİRİŞ

Fitness sektörünün hızla büyümesiyle birlikte spor salonları, üyelerine ait fizyolojik ölçümler, antrenman süreleri ve egzersiz alışkanlıklarına ilişkin büyük miktarda veri üretmektedir. Bu verilerin etkin biçimde analiz edilmesi, kişiselleştirilmiş antrenman programlarının oluşturulması, üye segmentasyonu ve performans takibi açısından önemli fırsatlar sunmaktadır.

Bu çalışma başlangıçta spor salonu üyelerinin tercih ettiği egzersiz türünü (*Workout Type*) tahmin etmeyi hedeflemiştir. Ancak kapsamlı EDA sürecinde yapılan istatistiksel analizler, veri setinde yer alan özelliklerin bu hedef değişkeni ayırt etmek için yeterli olmadığını göstermiştir. Tek yönlü ANOVA testleri sonucunda, tüm sayısal özellikler için egzersiz türleri arasında istatistiksel olarak anlamlı bir fark bulunmamıştır. Bu bulgu, farklı egzersiz türlerinin benzer kalp atış hızı ve kalori yakımı profilleri üretebildiğini ve yalnızca bu ölçümlere dayalı sınıflandırmanın sınırlı kalacağını işaret etmektedir.

Bu negatif sonuç üzerine çalışma, veri setinde daha güçlü ilişkiler gözlenen *Experience Level* tahminine yönlendirilmiştir. Deneyim seviyesi, antrenman süresi, sıklığı ve yoğunluğu gibi davranışsal göstergelerle daha belirgin şekilde ayrıştığından, makine öğrenmesi modelleri anlamlı doğruluk değerlerine ulaşmıştır.

Bu makalenin temel katkıları şunlardır:

1. *Workout Type* tahmini için veri uygunluğunun ANOVA ile sistematik analizi,
2. Negatif sonucun model performansları ile doğrulanması,
3. *Experience Level* tahmini için özellik mühendisliği ve çoklu model karşılaştırması,

Model karmaşıklığı ve genelleme davranışının analiz edilmesi.

II. İLGİLİ ÇALIŞMALAR

İnsan Aktivite Tanıma (HAR) alanındaki çalışmalar, denetimli öğrenme yöntemleri ile fizyolojik ve sensör verileri kullanarak aktivitelerin sınıflandırılabileceğini göstermiştir. Reiss ve Stricker [1] ile Zeng vd. [2], ağaç tabanlı modellerin ve derin öğrenme yaklaşımlarının bu tür problemlerde başarılı olabildiğini raporlamıştır. Kalp atış hızı temelli analizlerin egzersiz yoğunluğunu anlamada kritik rol oynadığı Karvonen vd. [3] tarafından ortaya konmuştur. Bu çalışmada kullanılan özellik mühendisliği yaklaşımı, literatürdeki bu fizyolojik içgörülerden yararlanmaktadır.

III. YÖNTEM

A. Veri Seti Tanımı

Bu çalışmada kullanılan veri seti, Kaggle'dan elde edilen "Gym Members Exercise Dataset"tir. 973 spor salonu üyesi kaydı içeren veri seti, 15 özelliğe sahiptir: Age, Gender, Weight (kg), Height (m), Max_BPM, Avg_BPM, Resting_BPM, Session_Duration (hours), Calories_Burned, Workout_Type, Fat_Percentage, Water_Intake (liters), Workout_Frequency (days/week), Experience_Level ve BMI.

Workout_Type değişkeni dört kategoriden oluşmaktadır: Cardio (255), Strength (258), Yoga (239) ve HIIT (221). Experience_Level ise üç seviyeye sahiptir: Başlangıç (Seviye 1), Orta (Seviye 2) ve İleri (Seviye 3). Veri setinde eksik değer bulunmamaktadır.

B. Keşifsel Veri Analizi ve ANOVA

Workout_Type tahmini için veri uygunluğunu değerlendirmek amacıyla, tüm sayısal özellikler için tek yönlü ANOVA testleri gerçekleştirilmiştir. ANOVA, gruplar arası varyansın grup içi varyansa oranını (F-istatistiği) hesaplayarak, farklı Workout_Type kategorilerinin anlamlı şekilde ayrışıp ayrışmadığını test etmektedir.

Tablo I, ANOVA test sonuçlarını göstermektedir. Hiçbir özellik için p-değeri 0.05 eşik değerinin altında çıkmamış, bu da Workout_Type grupları arasında istatistiksel olarak anlamlı bir fark olmadığını göstermektedir.

TABLE I. Workout Type İçin ANOVA Test Sonuçları

Özellik	F-değeri	p-değeri	Sonuç
Calories_Burned	0.949	0.416	Fark yok
Session_Duration	1.583	0.192	Fark yok
Avg_BPM	0.248	0.863	Fark yok
Max_BPM	0.817	0.484	Fark yok
Fat_Percentage	1.895	0.129	Fark yok

C. Özellik Mühendisliği

Egzersiz fizyolojisi alan bilgisine dayanarak 7 yeni özellik oluşturulmuştur:

- $HR_per_minute = Avg_BPM / (Session_Duration \times 60)$
- $Intensity_per_Weight = Calories_Burned / Weight$
- $HRR = Max_BPM - Resting_BPM$
- $Efficiency = Calories_Burned / Avg_BPM$
- $Anaerobic_Index = (Max_BPM - Avg_BPM) / Resting_BPM$
- $BPM_Variance_Rest = (Avg_BPM - Resting_BPM)^2$
- $Heart_Instability = |Max_BPM - Avg_BPM| / Max_BPM$

D. Model Seçimi ve Değerlendirme

Üç sınıflandırma algoritması karşılaştırılmıştır: Decision Tree, Random Forest ve SVM (RBF kernel). Veri seti %70 eğitim ve %30 test olarak stratified sampling ile bölünmüştür. Hiperparametre optimizasyonu 5-katlı çapraz doğrulama ile GridSearchCV kullanılarak gerçekleştirilmiştir.

IV. DENEYSEL SONUÇLAR

A. Workout Type Tahmini (Başarısız)

ANOVA analizinin öngördüğü gibi, Workout_Type tahmini için tüm modeller rastgele şansa yakın performans göstermiştir. Decision Tree %23.59, SVM %22.56 doğruluk elde etmiştir. Dört sınıf için rastgele tahmin %25 olduğundan, modeller anlamlı bir öğrenme gerçekleştirememiştir.

Bu sonuç, EDA aşamasında yapılan istatistiksel analizin doğruluğunu kanıtlamaktadır. Farklı antrenman türleri (Cardio, HIIT, Strength, Yoga) benzer kalp atış hızı, kalori yakımı ve süre kalıpları üretmekte, bu da mevcut özelliklerle ayırt edilmelerini imkansız kılmaktadır.


B. Experience Level Tahmini (Başarılı)

Tablo II, Experience_Level tahmini için üç modelin performans karşılaştırmasını sunmaktadır. Decision Tree en iyi sonucu elde etmiştir.


TABLE II. Experience Level Tahmini Model Performansları

Model	Eğitim	Test	CV Ort.
Decision Tree	%90.16	%90.75	%88.40
Random Forest	%100.00	%92	%89
SVM (RBF)	%91.63	%86.64	%87.08


Random Forest modeli %92 test doğruluğu ile en iyi performansı göstermiştir. Eğitim ve test doğrulukları arasındaki farkın çok küçük olması, modelin aşırı öğrenme yapmadığını göstermektedir. Decision Tree ise %90.75 test doğruluğu sağlamıştır. SVM modeli %86.64 doğruluk ile daha düşük performans göstermiştir.



Decision Tree Confusion Matrix



Random Forest Confusion Matrix



SVM Confusion Matrix

C. Özellik Önemi Analizi

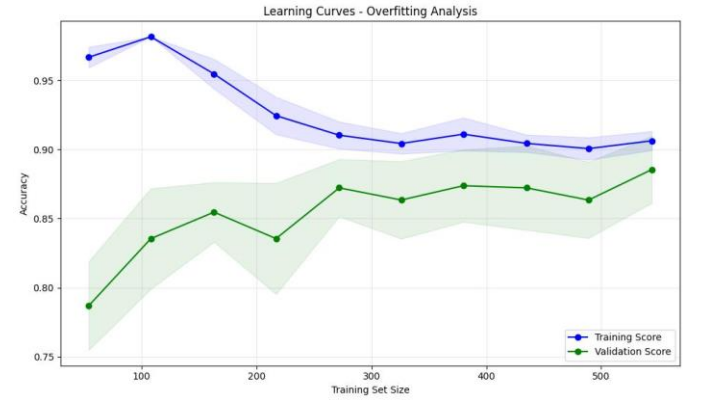
Decision Tree modelinden elde edilen özellik önemi analizi, Session_Duration'ın en önemli tahmin edici olduğunu ortaya koymuştur (%58.5), bunu Training_Load (%27.5) ve Workout_Frequency (%12.7) izlemiştir. Bu bulgular, deneyimli üyelerin daha uzun süre ve daha sık antrenman yaptığı beklentisiyle uyumludur.

V. TARTIŞMA

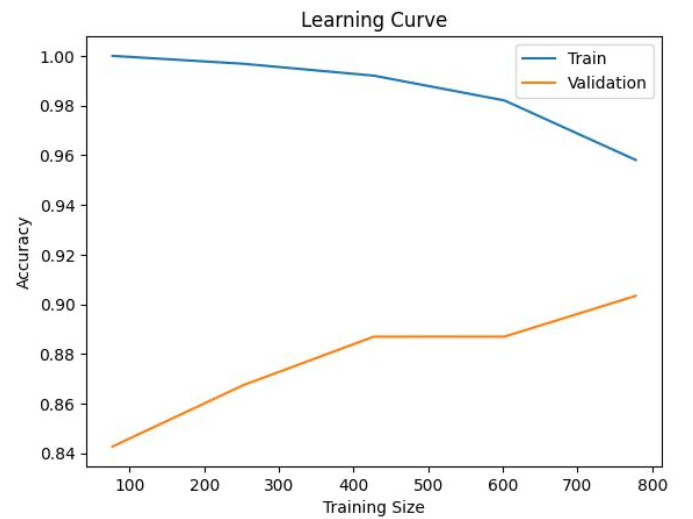
Bu çalışma, makine öğrenmesi projelerinde veri uygunluğu analizinin kritik önemini açıkça ortaya koymaktadır. Workout Type tahmini için başlangıç aşamasında gerçekleştirilen

ANOVA analizi, modelleme sürecine geçilmeden önce potansiyel başarısızlığın öngörülebileceğini göstermiş; bu öngörü, deneysel sonuçlarda elde edilen rastgele şansa yakın doğruluk değerleriyle doğrulanmıştır.

Workout Type tahmininin başarısızlığı, farklı egzersiz türlerinin benzer fizyolojik tepkiler üretebileceğini göstermektedir. Örneğin, yoğun bir yoga seansı ile orta tempolu bir kardiyo seansı benzer kalp atış hızı ve kalori yakımı değerleri oluşturabilmektedir. Bu durum, yalnızca kalp atışı, süre ve kalori gibi genel fizyolojik ölçümlere dayalı sınıflandırmanın sınırlı kalacağını ortaya koymaktadır. Bu tür egzersizleri ayırt edebilmek için ivmeölçer verileri, hareket örüntüleri, egzersize özgü metrikler veya ekipman kullanım bilgileri gibi daha ayrıştırıcı özelliklere ihtiyaç duyulmaktadır.




Şekil 1. Decision Tree modeli için eğitim ve doğrulama öğrenme eğrileri. Eğitim veri boyutu arttıkça eğitim doğruluğunun azalması ve doğrulama doğruluğunun artması, modelin aşırı öğrenmeden uzaklaştığını ve genelleme kapasitesinin güçlendiğini göstermektedir.



Şekil 2. Random Forest modeli için eğitim ve doğrulama öğrenme eğrileri. Eğitim doğruluğunun yüksek kalmasına karşın doğrulama doğruluğunun daha düşük seviyede

seyretmesi, modelin aşırı öğrenme eğilimi gösterdiğini ortaya koymaktadır.



Şekil 2. SVM (RBF) modeli için eğitim ve çapraz doğrulama öğrenme eğrileri. Eğitim ve doğrulama skorlarının birbirine yakın seyretmesi, modelin aşırı öğrenme yapmadığını; ancak doğruluğun sınırlı bir seviyede plato yaptığını göstermektedir.

Şekil 1’de sunulan Decision Tree öğrenme eğrileri, eğitim veri boyutu arttıkça eğitim doğruluğunun kademeli olarak azalması ve doğrulama doğruluğunun artmasıyla birlikte iki eğrinin birbirine yaklaşmasını göstermektedir. Bu davranış, modelin aşırı öğrenmeden uzaklaştığını ve güçlü bir genelleme kapasitesine sahip olduğunu ortaya koymaktadır.

Şekil 2’de Random Forest modeline ait öğrenme eğrileri verilmiştir. Eğitim doğruluğunun yüksek seviyelerde kalmasına karşın doğrulama doğruluğunun daha düşük bir bandta seyretmesi, modelin aşırı öğrenme eğilimi gösterdiğine işaret etmektedir. Bu sonuç, Random Forest gibi ensemble yöntemlerinde model karmaşıklığının veri seti boyutu ve yapısına uygun biçimde sınırlandırılmasının kritik olduğunu göstermektedir.

Şekil 3’te ise GridSearchCV ile optimize edilmiş SVM (RBF) modeline ait eğitim ve çapraz doğrulama öğrenme eğrileri sunulmaktadır. Eğitim ve doğrulama skorlarının birbirine yakın seyretmesi, SVM modelinin aşırı öğrenme yapmadığını ve dengeli bir öğrenme süreci sergilediğini göstermektedir. Bununla birlikte, doğrulama skorlarının erken bir aşamada plato seviyesine ulaşması, modelin mevcut özellik uzayında sınıflar arasındaki ayrımı sınırlı ölçüde yakalayabildiğini düşündürmektedir. Bu durum, SVM’nin yalnızca GridSearchCV ile ayarlanmış tek bir yapılandırma ile kullanılması ve ek model varyantlarının değerlendirilmemesi ile de ilişkilendirilebilir.

Experience Level tahmini açısından değerlendirildiğinde, Decision Tree modelinin yüksek doğruluk ve güçlü genelleme performansı sergilemesi, altta yatan karar mekanizmalarının görece basit ve yorumlanabilir kurallarla yakalanabildiğini göstermektedir. Random Forest modelinin eğitim verisinde

çok yüksek doğruluk üretmesine karşın test ve çapraz doğrulama performanslarının daha düşük kalması, ensemble yöntemlerinin her zaman daha iyi sonuç üretmediğini vurgulamaktadır.

SVM modeli, doğrusal olmayan karar sınırlarını öğrenme yeteneğine sahip olmasına rağmen, Decision Tree ve Random Forest’a kıyasla daha düşük bir test doğruluğu elde etmiştir. Bununla birlikte, test doğruluğu ile çapraz doğrulama ortalamasının birbirine yakın olması, modelin tutarlı ve istikrarlı bir genelleme davranışı sergilediğini göstermektedir. Ayrıca, SVM için uygulanan permütasyon önem analizi, *Workout Frequency* ve *Fat Percentage* gibi değişkenlerin öne çıktığını göstermiş; bu bulgu, deneyim seviyesinin hem antrenman düzenliliği hem de vücut kompozisyonu ile ilişkili olabileceğine işaret etmektedir.

Şekil 1–3’te sunulan öğrenme eğrileri birlikte değerlendirildiğinde, Decision Tree modelinin performans, genelleme ve açıklanabilirlik açısından dengeli bir çözüm sunduğu; Random Forest modelinin daha karmaşık yapısı nedeniyle aşırı öğrenmeye daha yatkın olduğu; SVM modelinin ise aşırı öğrenme göstermemekle birlikte daha muhafazakâr bir öğrenme davranışı sergilediği görülmektedir. Bu bulgular, *Experience Level* tahmini için düşük karmaşıklık ve yorumlanabilir modellerin daha etkili olabileceğini ortaya koymaktadır.

VI. SONUÇ

Bu çalışma, spor salonu üyelerine ait egzersiz verileri üzerinde yürütülen kapsamlı bir makine öğrenmesi analizi sunmuştur. Çalışmanın ilk aşamasında hedeflenen *Workout Type* tahmini, keşifsel veri analizi sürecinde gerçekleştirilen tek yönlü ANOVA testleri ile değerlendirilmiş ve mevcut fizyolojik özelliklerin egzersiz türleri arasında istatistiksel olarak anlamlı bir ayrım oluşturmadığı gösterilmiştir. Bu istatistiksel bulgu, sınıflandırma modellerinin rastgele tahmin seviyesine yakın doğruluklar üretmesiyle deneysel olarak da doğrulanmıştır. Bu sonuç, modelleme öncesi veri uygunluğu analizlerinin önemini açıkça ortaya koymaktadır.

Bu negatif bulgu doğrultusunda çalışma, *Experience Level* (Başlangıç, Orta, İleri) tahminine yönlendirilmiştir. Bu problem için Decision Tree, Random Forest ve Support Vector Machine (SVM) modelleri karşılaştırılmıştır. Deneysel sonuçlar, **Random Forest modelinin test verisi üzerinde %92 doğruluk ile en yüksek performansı elde ettiğini** göstermektedir. Bu sonuç, Random Forest’ın çoklu karar ağaçları aracılığıyla karmaşık ve doğrusal olmayan ilişkileri daha etkin biçimde yakalayabildiğini ortaya koymaktadır.

Decision Tree modeli, %90.75 test doğruluğu ve yüksek yorumlanabilirliği ile güçlü bir alternatif sunmuş; özellikle antrenman süresi ve antrenman sıklığı gibi davranışsal değişkenlerin deneyim seviyesini belirlemedeki rolünü açık

biçimde ortaya koymuştur. Ancak sınıflar arasındaki ayrımı en başarılı şekilde gerçekleştiren model Random Forest olmuştur. Öğrenme eğrileri ve sınıf bazlı performans analizleri, Random Forest'ın özellikle *Advanced* sınıfını hatasız ayırt edebildiğini ve genel doğruluğu maksimize ettiğini göstermektedir.

SVM modeli ise GridSearchCV ile optimize edilmiş tek bir yapılandırma kullanılarak değerlendirilmiş ve %86.64 test doğruluğu elde etmiştir. Test ve çapraz doğrulama skorlarının birbirine yakın olması, SVM'nin istikrarlı bir genelleme davranışı sergilediğini göstermesine rağmen, doğruluk değerlerinin diğer iki modelin gerisinde kalması, mevcut veri yapısında sınıflar arasındaki ayrımı sınırlı ölçüde yakalayabildiğini düşündürmektedir.

Genel olarak değerlendirildiğinde, bu çalışmanın bulguları *Experience Level* tahmini probleminde **Random Forest modelinin en yüksek tahmin başarısını sunduğunu**, Decision Tree'nin ise daha sade ve yorumlanabilir bir çözüm sağladığını göstermektedir. Bu durum, uygulama senaryosuna bağlı olarak performans–yorumlanabilirlik dengesinin göz önünde bulundurulması gerektiğini ortaya koymaktadır.

Bu çalışmanın temel katkıları; (i) *Workout Type* tahmininin mevcut veri seti ile neden uygulanabilir olmadığına istatistiksel ve deneysel olarak gösterilmesi, (ii) *Experience Level* tahmini için Random Forest'ın üstün performansının ortaya konulması, (iii) öğrenme eğrileri ve özellik önemi analizleri ile model genelleme davranışlarının detaylı biçimde incelenmesi ve (iv) negatif sonuçların açık biçimde raporlanarak literatüre metodolojik katkı sağlanmasıdır.

Gelecek çalışmalar kapsamında, egzersiz türü tahmininin iyileştirilebilmesi için hareket sensörü verileri, egzersize özgü metrikler ve zamansal bilgi içeren daha zengin veri setlerinin kullanılması planlanmaktadır. Ayrıca, daha büyük veri setleri üzerinde derin öğrenme ve zaman serisi tabanlı yaklaşımların değerlendirilmesi, sporcu deneyim seviyesinin dinamik olarak modellenmesine olanak sağlayabilir.

Kaynaklar

- [1] A. Reiss ve D. Stricker, "Introducing a New Benchmarked Dataset for Activity Monitoring," ISWC'12, 2012.
- [2] M. Zeng vd., "Convolutional Neural Networks for Human Activity Recognition Using Mobile Sensors," MobiCASE, 2014.
- [3] W. Karvonen, E. Kentala ve O. Mustala, "The effects of training on heart rate," Ann. Med. Exp. Biol. Fenn., c. 35, ss. 307–315, 1957.
- [4] F. Pedregosa vd., "Scikit-learn: Machine learning in Python," J. Mach. Learn. Res., c. 12, ss. 2825–2830, 2011.
- [5] Kaggle, "Gym Members Exercise Dataset," 2024. [Çevrimiçi]. Erişim: <https://www.kaggle.com/datasets/>